

# Ch 17 Markov and Hidden Markov Model

# 17.3 Hidden Markov Model

- discrete-time, discrete-state Markov chain
- · with hidden state and observation model



**Figure 10.3** A first and second order Markov chain.



**Figure 10.4** A first-order HMM.

### 결합 확률

• 은닉 상태 천이확률과 조건부 관측확률로 표현 가능


$$p(\mathbf{z}_{1:T}, \mathbf{x}_{1:T}) = p(\mathbf{z}_{1:T})p(\mathbf{x}_{1:T}|\mathbf{z}_{1:T}) = \left[p(z_1)\prod_{t=2}^{T}p(z_t|z_{t-1})\right]\left[\prod_{t=1}^{T}p(\mathbf{x}_t|z_t)\right]$$
(17.39)

# 관측(observations)

- discrete 인 경우 observation matrix로 표현 가능
- continuous 인 경우 conditional gaussian으로 표현 가능

$$p(\mathbf{x}_t = l|z_t = k, \boldsymbol{\theta}) = B(k, l) \tag{17.40}$$

$$p(\mathbf{x}_t|z_t = k, \boldsymbol{\theta}) = \mathcal{N}(\mathbf{x}_t|\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)$$
(17.41)



**Figure 17.7** (a) Some 2d data sampled from a 3 state HMM. Each state emits from a 2d Gaussian. (b) The hidden state sequence. Based on Figure 13.8 of (Bishop 2006b). Figure generated by hmmLillypadDemo.

### 17.3.1 HMM의 응용

- black-box density models on sequences
- long-range dependencies between observations mediated via the latent variables

# 음성 인식

● 관측 : 음성 신호

은닉 상태 : 단어

• 상태 천이 모델 : p(z\_i | z\_j ), language model

• 관측 모델 : p(x|z), acoustic model

# **Speech tagging**

● 관측 : 단어

• 은닉 상태 : POS(part of speech, ex. noun, verb, adjective)

상태 천이 모델 : grammer model

## 비디오로부터 활동 인식

• 관측 : 영상 feature

• 은닉 상태 : class of activity, ex) 뛰기, 걷기, 앉기..


# 17.4 Inference in HMMs

- inference란?
  - 관측열을 보고, 내제된 은닉 상태열을 추정하는 것
  - 편의상, 모든 모델 파라미터는 안다고 가정

## 부정직한 카지노 예제

- 공평(fair) 주사위 v.s 불공정(loaded) 주사위
- 관측열(rolls)를 보고, 어느시점에 어느 주사위가 던져졌는지 추론

### Listing 17.1 Example output of casinoDemo



### 17.4.1 Inference의 종류

#### **Filtering**

- 과거부터 현재까지의 관측열(x\_1 ~ x\_t)를 보고, 현재의 은닉 상태(z\_t)를 추정하는 것
- on-line as data streams in




#### **Smoothing**

- 모든 관측(과거,현재,미래)을 보고, 특정시점의 은닉 상태(z\_t) 추정
- 추가적 정보를 바탕으로 필터링 결과를 smooth
- hindsight, 지나고 나서야 나중에 깨닫는 것
- offline



#### **Fixed-lag smoothing**

- smoothing이기는 하지만 lag 정도의 시점의 은닉 상태 추정
- offline과 online의 특성 조합
- lag가 작아지면 판단 delay는 작아서 좋지만 정확도가 떨어진다.



#### **Prediction**

• 과거(그리고 현재) 관측을 바탕으로 미래 상태나 미래 관측 예측



$$p(z_{t+2}|\mathbf{x}_{1:t}) = \sum_{z_{t+1}} \sum_{z_t} p(z_{t+2}|z_{t+1}) p(z_{t+1}|z_t) p(z_t|\mathbf{x}_{1:t})$$
(17.42)

$$p(\mathbf{x}_{t+h}|\mathbf{x}_{1:t}) = \sum_{z_{t+h}} p(\mathbf{x}_{t+h}|z_{t+h}) p(z_{t+h}|\mathbf{x}_{1:t})$$
(17.43)

#### **MAP** estimation

- 모든 관측열을 바탕으로 가장 적합한 은닉 상태열을 추정하는 것
- ex) 음성으로 한 문장 듣기 => 단어열로 표현
- Viterbi-decoding

$$\arg\max_{\mathbf{z}_{1:T}} p(\mathbf{z}_{1:T}|\mathbf{x}_{1:T})$$

#### **Posterior samples**

sample from posterior

$$\mathbf{z}_{1:T} \sim p(\mathbf{z}_{1:T}|\mathbf{x}_{1:T}).$$

#### Probability of evidence

- 관측열 자체의 발생 확률
- 모든 가능한 은닉 상태열 경로를 모두 summing up 한 것

$$p(\mathbf{x}_{1:T}) = \sum_{\mathbf{z}_{1:T}} p(\mathbf{z}_{1:T}, \mathbf{x}_{1:T})$$

### 17.4.2 Forward Algorithm

● 필터링을 얻고 싶다. p(z\_t | x\_1:t)

### 첫 번째 step : one-step ahead state prediction

- local evidence from anywhere \* transition prob
- act as the new prior(belief) for time t

$$p(z_t = j | \mathbf{x}_{1:t-1}) = \sum_i p(z_t = j | z_{t-1} = i) p(z_{t-1} = i | \mathbf{x}_{1:t-1})$$
(17.44)

#### 두번째 step: update

- update belief given observation
- one-step ahead prediction 과 local evidence 를 곱한 후 normalize
- 취소선 : 조건부 독립

$$\alpha_t(j) \triangleq p(z_t = j | \mathbf{x}_{1:t}) = p(z_t = j | \mathbf{x}_t, \mathbf{x}_{1:t-1})$$

$$(17.45)$$


$$= \frac{1}{Z_t} p(\mathbf{x}_t | z_t = j, \mathbf{x}_{1:t-1}) p(z_t = j | \mathbf{x}_{1:t-1})$$

$$(17.46)$$


$$\alpha_t \propto \psi_t \odot (\Psi^T \alpha_{t-1})$$
 (17.48)

where  $\psi_t(j) = p(\mathbf{x}_t|z_t = j)$  is the local evidence at time t,  $\Psi(i,j) = p(z_t = j|z_{t-1} = i)$  is the transition matrix, and  $\mathbf{u} \odot \mathbf{v}$  is the **Hadamard product**, representing elementwise vector

### 참고: 조건부 독립



- a) s가 관측되면 a,b는 조건부 독립
  - P(a|s,a) = P(a|s), P(b|s,a) = P(b|s)
- b) common-cause가 관측되면, effect들은 독립



- c) result가 관측되면 원인들끼리 종속
  - 결근 by 휴가 or 질병
  - V-structured, explaining away

# 17.4.3 Forward-Backward Algorithm

- 최종 목적은 smoothed marginal을 구하는 것
  - p(z\_t | x\_1:T)
- 아래처럼 과거로부터 오는 chain과 미래로부터 온 chain으로 분리해서 생각
  - alpha: filtered belief state
  - beta : conditional likelihood of future evidence

The key decomposition relies on the fact that we can break the chain into two parts, the past and the future, by conditioning on  $z_t$ :

$$p(z_t = j|\mathbf{x}_{1:T}) \propto p(z_t = j, \mathbf{x}_{t+1:T}|\mathbf{x}_{1:t}) \propto p(z_t = j|\mathbf{x}_{1:t})p(\mathbf{x}_{t+1:T}|z_t = j, \mathbf{x}_{t:t})$$
(17.50)

Let  $\alpha_t(j) \triangleq p(z_t = j | \mathbf{x}_{1:t})$  be the filtered belief state as before. Also, define

$$\beta_t(j) \triangleq p(\mathbf{x}_{t+1:T}|z_t = j) \tag{17.51}$$

- beta도 DP 방식으로 계산 가능
  - one-step after beta, local evidence, 상태 천이 확률
  - 취소선 : 조건부 독립

$$\beta_{t-1}(i) = p(\mathbf{x}_{t:T}|z_{t-1} = i)$$

$$= \sum_{i} p(z_t = j, \mathbf{x}_t, \mathbf{x}_{t+1:T}|z_{t-1} = i)$$
(17.54)
$$(17.55)$$

$$= \sum_{i}^{J} p(\mathbf{x}_{t+1:T}|z_{t} = j, \underline{z_{t-1}} = i, \underline{\mathbf{x}_{t}}) p(z_{t} = j, \mathbf{x}_{t}|z_{t-1} = i)$$
(17.56)

$$= \sum_{j} p(\mathbf{x}_{t+1:T}|z_t = j) p(\mathbf{x}_t|z_t = j, \underline{z_t} = i) p(z_t = j|z_{t-1} = i)$$
 (17.57)

$$= \sum_{j} \beta_t(j)\psi_t(j)\psi(i,j) \tag{17.58}$$

- state의 cardinality : K
- end of sequence : T

### naive 한 구현인 경우

- O( K^2 \* T )의 시간 복잡도
  - 각 time-step마다 K by K matrix 를 곱해야 하므로
  - K가 매우 크면(ex. 언어 모델) 계산 어려움

### sparse한 transition matrix 라면

• O(TK)의 시간 복잡도

#### 공간 복잡도가 더 문제

- O(KT) for storing alpha, betea
- divide-conquer 방법을 쓰면 O(K\*logT)로 줄어듬, 반대 급부로 시간 복잡도 증가

### 17.4.4 Viterbi 알고리즘

- 모든 관측열을 바탕으로 가장 적합한 은닉 상태열을 추정하는 것
- trellis diagram에서 최단 경로에 해당

$$\mathbf{z}^* = \arg\max_{\mathbf{z}_{1:T}} p(\mathbf{z}_{1:T}|\mathbf{x}_{1:T}) \tag{17.68}$$

#### MAP와 MPM의 차이

- MAP
  - Maximum a posterior
  - most probable sequence of states
- MPM
  - maximization of the posterior marginals
  - sequence of (marginally) most probable states

$$\hat{\mathbf{z}} = (\arg\max_{z_1} p(z_1|\mathbf{x}_{1:T}), \dots, \arg\max_{z_T} p(z_T|\mathbf{x}_{1:T}))$$
(17.70)

#### MPM은 MAP보다 robust 하다.

why, note that in Viterbi, when we estimate  $z_t$ , we "max out" the other variables:

$$z_t^* = \arg\max_{z_t} \max_{\mathbf{z}_{1:t-1}, \mathbf{z}_{t+1:T}} p(\mathbf{z}_{1:t-1}, z_t, \mathbf{z}_{t+1:T} | \mathbf{x}_{1:T})$$
(17.71)

whereas we when we use forwards-backwards, we sum out the other variables:

$$p(z_t|\mathbf{x}_{1:T}) = \sum_{\mathbf{z}_{1:t-1}, \mathbf{z}_{t+1:T}} p(\mathbf{z}_{1:t-1}, z_t, \mathbf{z}_{t+1:T}|\mathbf{x}_{1:T})$$
(17.72)

#### 17.4.4.2 Viterbi 알고리즘 상세


- - - - - -

- delta : 현재까지의 최적의 path를 거칠 확률
  - 그 이전까지의 path도 최적이어야 한다.

$$\delta_t(j) \triangleq \max_{z_1, \dots, z_{t-1}} p(\mathbf{z}_{1:t-1}, z_t = j | \mathbf{x}_{1:t})$$

$$(17.73)$$

$$\delta_t(j) = \max_i \delta_{t-1}(i)\psi(i,j)\phi_t(j) \tag{17.74}$$



# 17.4.5 Forward filtering, bacward sampling

• sample paths from posterior

$$\mathbf{z}_{1:T}^s \sim p(\mathbf{z}_{1:T}|\mathbf{x}_{1:T}) \tag{17.83}$$

do the forward pass, and then perform sampling in the backward pass

$$p(\mathbf{z}_{1:T}|\mathbf{x}_{1:T}) = p(z_T|\mathbf{x}_{1:T}) \prod_{t=T-1}^{T} p(z_t|z_{t+1},\mathbf{x}_{1:T})$$
(17.84)

We can then sample  $z_t$  given future sampled states using

$$z_t^s \sim p(z_t|z_{t+1:T}, \mathbf{x}_{1:T}) = p(z_t|z_{t+1}, \mathbf{z}_{t+2:T}, \mathbf{x}_{1:t}, \mathbf{x}_{t+1:T}) = p(z_t|z_{t+1}^s, \mathbf{x}_{1:t})$$
 (17.85)

The sampling distribution is given by

$$p(z_t = i | z_{t+1} = j, \mathbf{x}_{1:t}) = p(z_t | z_{t+1}, \mathbf{x}_{1:t}, \mathbf{x}_{t+1})$$
(17.86)

$$= \frac{p(z_{t+1}, z_t | \mathbf{x}_{1:t+1})}{p(z_{t+1} | \mathbf{x}_{1:t+1})}$$
(17.87)

$$\propto \frac{p(\mathbf{x}_{t+1}|z_{t+1}, \mathbf{x}_{t}, \mathbf{x}_{1:t})p(z_{t+1}, z_{t}|\mathbf{x}_{1:t})}{p(z_{t+1}|\mathbf{x}_{1:t+1})}$$
(17.88)

$$= \frac{p(\mathbf{x}_{t+1}|z_{t+1})p(z_{t+1}|z_t,\mathbf{x}_{1:t})p(z_t|\mathbf{x}_{1:t})}{p(z_{t+1}|\mathbf{x}_{1:t+1})}$$
(17.89)

$$= \frac{\phi_{t+1}(j)\psi(i,j)\alpha_t(i)}{\alpha_{t+1}(j)} \tag{17.90}$$